文章编号:1007-5321(2023)03-0043-06 **DOI**:10.13190/j.jbupt.2022-208

基于 DDPG 的无人机轨迹规划及功率控制算法

杨青青[1,2], 陈 剑[1], 彭 艺[1,2]
(1. 昆明理工大学 信息工程与自动化学院, 昆明 650500; 2. 昆明理工大学 云南省计算机技术应用重点实验室, 昆明 650500)

摘要: 针对无人机辅助地面用户下行通信的场景,以用户的最小平均可达速率最大化为目标,提出了无人机轨迹约束、功率约束和用户接入调度的优化问题。考虑到约束条件的耦合性和优化问题的非凸性,将构建的优化问题建模为马可科夫决策过程,提出了一种基于深度确定性策略梯度(DDPG)的无人机轨迹规划和功率控制算法。仿真结果表明,所提算法能够有效地提高用户的最小平均可达速率。

关 键 词: 无人机; 轨迹规划; 功率控制; 马尔可夫决策过程; 深度确定性策略梯度
中图分类号: TN929.52 **文献标志码**: A

Unmanned Aerial Vehicle Trajectory Planning and Power Control Algorithm Based on Deep Deterministic Policy Gradient

YANG Qingqing[1,2], CHEN Jian[1], PENG Yi[1,2]
(1. Faculty of Information Engineering and Automation, Kunming University of Science and Technology, Kunming 650500, China;
2. Yunnan Key Laboratory of Computer Technologies Application, Kunming University of Science and Technology, Kunming 650500, China)

Abstract: Aiming at the scenario where unmanned aerial vehicles assist users on the ground to carry out downlink communication, the optimization problem of unmanned aerial vehicle trajectory constraint, power constraint and user access scheduling is established with the objective of maximizing the minimum average reachable rate of users. Considering the coupling of the constraints and the non-convexity of the optimization problem, the constructed optimization problem is modeled as a Markov decision process, and a trajectory planning and power control algorithm of unmanned aerial vehicle-based on deep deterministic policy gradient (DDPG) is proposed. Simulation results show that the proposed algorithm can effectively improve the minimum average achievable rate of users.

Key words: unmanned aerial vehicle; trajectory planning; power control; Markov decision process; deep deterministic policy gradient

无人机具有高移动性、低成本和按需部署等优势,可以作为临时基站来辅助无线通信,具有广阔的应用前景[1]。早期关于无人机辅助通信的研究主要针对无人机的静态部署,通过对无人机的水平位置和高度进行优化,以满足不同的通信需求[2]。和地面基站不同,空地通信模型中的路径损耗由无人机和用户的位置共同决定[3],静态的无人机基站难以发挥其优势,因此有学者针对无人机的动态部署问题进行了研究。Lyu 等[4]提出了一种基于多项时间算法的无人机动态部署方案以提高可覆盖的用户

收稿日期: 2022-08-19
基金项目: 云南省计算机技术应用重点实验室开发基金资助项目(2021102)
作者简介: 杨青青(1981—), 女, 讲师, 硕士生导师。
通信作者: 彭 艺(1975—), 女, 副教授, 硕士生导师。

数量,并证明了该算法在时间复杂度方面优于其他算法。Zeng 等[5]推导了固定翼无人机推进能量消耗与飞行速度、方向和加速度函数关系的理论模型,并通过轨迹设计实现了能量效率的最大化,提高了通信的服务质量。

除此之外,也有文献指出无人机基站发射功率的合理分配能够提高系统性能,Liu 等[6]通过访问优先级确定用户的分组方案,利用消息传递算法对信道进行分配;然后联合优化了无人机基站的发射功率,提高了系统性能。Tang 等[7]通过惩罚函数法和逐次凸逼近法来求解无人机位置部署和功率分配的联合优化问题,从而提高用户的接入数量。

Zhao 等[8]指出,无人机的轨迹和功率的联合优化问题是非凸的,难以获得最优的联合优化策略,可以将此类问题建模为马尔可夫决策过程(MDP, Markov decision process),通过深度强化学习(DRL, deep reinforcement learning)算法来解决。因此,笔者将无人机作为移动基站为地面用户提供通信服务,以用户的最小平均速率最大化为目标,构建了无人机轨迹规划和功率控制的优化问题,并将此问题建模为 MDP,提出了一种基于深度确定性策略梯度(DDPG, deep deterministic policy gradient)的无人机轨迹规划和功率控制算法。

1 系统模型和问题建模

1.1 系统模型

图 1 所示为空地通信模型,携带有微型基站的 M 架无人机为目标区域的 K 个地面用户提供通信服务,$m=1,2,\cdots,M$,$k=1,2,\cdots,K$。假设无人机的服务时间为 T,部署高度固定为 H,无人机以时分多址的方式为所有地面用户提供服务。

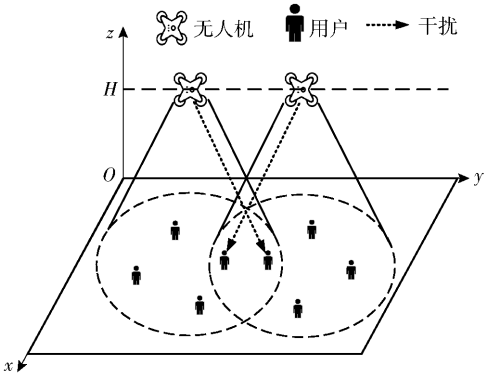

图 1 空地通信模型

为了便于描述无人机的轨迹,采用离散近似的方法将无人机的持续服务时间 T 划分为 N 个等长时隙 δ,即 $\delta=T/N$,当时隙足够小时,可以认为在 2 个相邻时隙中无人机的位置近似不变。地面用户的位置固定不变,第 k 个用户的坐标为 $\boldsymbol{w}_k=[x_k,y_k]^{\mathrm{T}}$,无人机 m 的坐标为 $\boldsymbol{m}[n]=[x[n],y[n]]^{\mathrm{T}}$,$n=1,2,\cdots,N$。

无人机的轨迹受诸多因素的限制,可将约束条件简化为始末位置约束、最大速度约束、碰撞约束和服务位置约束,分别表示为

$$\boldsymbol{m}[0]=\boldsymbol{m}_0,\boldsymbol{m}[N]=\boldsymbol{m}_{\mathrm{f}},\ \forall \boldsymbol{m},n \tag{1}$$

$$\|\boldsymbol{m}[n]-\boldsymbol{m}[n-1]\|^2\leqslant l_{\max}^2,\ \forall \boldsymbol{m},n \tag{2}$$

$$\|\boldsymbol{m}[n]-\boldsymbol{j}[n]\|^2\geqslant d_{\min}^2,\ \forall \boldsymbol{m},\boldsymbol{j},n,\boldsymbol{j}\neq\boldsymbol{m} \tag{3}$$

$$\boldsymbol{m}[n]\in D,\ \forall \boldsymbol{m},n \tag{4}$$

其中:$\boldsymbol{m}_0$ 和 $\boldsymbol{m}_{\mathrm{f}}$ 为无人机的始末位置;$l_{\max}\triangleq v_{\max}\delta_t$,为无人机在每个时隙中可以移动的最大水平位置,$v_{\max}$ 为无人机的最大飞行速度;$\boldsymbol{m}[n]$ 和 $\boldsymbol{j}[n]$ 为不同无人机的位置;$d_{\min}$ 为无人机之间的安全距离;D 为无人机的服务区域。

1.2 通信模型

将无人机和用户之间的通信视为视距通信,因此信道质量只取决于他们之间的距离,无人机 m 和用户 k 之间的距离为

$$d_{m,k}[n]=\sqrt{\|\boldsymbol{m}[n]-\boldsymbol{w}_k\|^2+H^2} \tag{5}$$

无人机在第 n 个时隙与用户之间的信道增益遵循自由空间路径损耗模型,表示为

$$g_{m,k}[n]=\rho_0 d_{m,k}^{-2}[n]=\frac{\rho_0}{\|\boldsymbol{m}[n]-\boldsymbol{w}_k\|^2+H^2} \tag{6}$$

其中 ρ_0 为参考距离为 1 m 时的信道功率。

当无人机的数量大于 1 时,用户 k 接收信号可能会受到其他无人机的干扰,此时用户的信干噪比表示为

$$\gamma_{m,k}[n]=\frac{P_m[n]g_{m,k}[n]}{\sum\limits_{j=1,j\neq m}^{M}P_j[n]g_{j,k}[n]+\sigma^2} \tag{7}$$

其中:$P_m[n]$ 为无人机当前时隙的发射功率,$0\leqslant P_m[n]\leqslant P_{\max}$,$P_{\max}$ 为无人机的最大发射功率;σ^2 为用户处的加性高斯白噪声功率;$\sum\limits_{j=1,j\neq m}^{M}P_j[n]g_{j,k}[n]$ 为其他无人机的干扰。

为了协调用户的接入和通信资源的使用情况,引入二进制变量 $\alpha_{m,k}[n]$,表示用户的接入调度问题。当 $\alpha_{m,k}[n]=1$ 时,表示无人机在第 n 个时隙中

为用户 k 提供通信；否则，$\alpha_{m,k}[n]=0$。因此用户 k 在第 n 个时隙中的传输速率为

$$R_{m,k}[n]=\sum_{m=1}^{M}\alpha_{m,k}[n]\mathrm{lb}(1+\gamma_{m,k}[n]) \quad (8)$$

在 N 个时隙中用户可以实现的平均速率为

$$R_k=\frac{1}{N}\sum_{n=1}^{N}R_{m,k}[n] \quad (9)$$

1.3　问题描述

基于上述模型，通过对无人机的轨迹、功率控制和用户接入调度进行优化，使用户的最小平均速率最大化，该优化问题描述如下。

$$\begin{aligned}
&\max \quad \min \quad R_k\\
&\text{s.t.} \quad R_k=\frac{1}{N}\sum_{n=1}^{N}\sum_{m=1}^{M}\alpha_{m,k}[n]\mathrm{lb}(1+\gamma_{m,k}[n])\\
&\text{C1:} \quad \boldsymbol{m}[0]=\boldsymbol{m}_0,\boldsymbol{m}[N]=\boldsymbol{m}_{\mathrm{f}},\ \forall \boldsymbol{m},n\\
&\text{C2:} \quad \|\boldsymbol{m}[n]-\boldsymbol{m}[n-1]\|^2\leqslant l_{\max}^2,\forall \boldsymbol{m},n\\
&\text{C3:} \quad \|\boldsymbol{m}[n]-\boldsymbol{j}[n]\|^2\geqslant d_{\min}^2,\forall \boldsymbol{m},\boldsymbol{j},n,\boldsymbol{j}\neq\boldsymbol{m}\\
&\text{C4:} \quad \boldsymbol{m}[n]\in D,\forall \boldsymbol{m},n\\
&\text{C5:} \quad 0\leqslant P_m[n]\leqslant P_{\max},\forall \boldsymbol{m},n\\
&\text{C6:} \quad \alpha_{m,k}[n]\in[0,1],\forall \boldsymbol{m},k,n
\end{aligned} \quad (10)$$

其中：C1～C4 为无人机的轨迹约束，包括无人机的始末位置、速度、无人机之间的安全距离以及服务区域，C5 为无人机的发射功率约束，C6 为用户的接入调度。

2　基于 DDPG 的无人机轨迹规划及功率控制算法

由于优化问题是无人机的轨迹变量和发射功率变量等的耦合，求解复杂度较高。因此通过将优化问题建模为 MDP 并运用 DDPG 算法解决该问题。

2.1　MDP 问题构建

MDP 是基于智能体和环境的交互产生的，包括状态、动作、奖励和转移概率，可以用一个元组（S，A，r，p）来定义；其中：S 为环境状态空间的集合；A 为智能体（即无人机）动作空间的集合；r 是将环境和智能体动作映射到奖励的函数；p 为智能体在执行动作之后从当前状态转移到下一状态的概率。MDP 构建如下。

1）状态空间。状态空间是智能体所处环境的集合，基于优化问题，系统在当前时隙 n 中的状态空间包括无人机和用户的位置信息以及各项约束，表示为

$$s_n=\{\boldsymbol{m}[n],\boldsymbol{w}_k,D,d_{\min},d_{m,k}[n]\},\ s_n\in S \quad (11)$$

2）动作空间。当前时隙 n 中系统的动作空间是无人机针对状态空间做出的动作集合，表示为

$$a_n=\{\boldsymbol{m}[n+1],P_m[n],\alpha_{m,k}[n]\},a_n\in A \quad (12)$$

3）奖励函数。奖励函数与目标函数相关，由正奖励和负奖励两部分组成。长期的奖励回报可定义为当前回报和未来每个可能状态的折扣回报之和，表示为

$$r_1=\sum_{n=1}^{N}Y^{n-i}r_n(s_n,a_n) \quad (13)$$

其中：$Y\in[0,1]$ 为奖励的折扣系数，i 为缓冲池中的第 i 组状态转换序列，r_n 为时隙 n 中智能体根据状态采取动作之后得到的奖励。从未来状态获得的奖励都需要乘以折扣系数。折扣系数越小，表明智能体更关注于当前奖励；折扣系数越大，表明未来的奖励对智能体更重要。为避免智能体只追求当前状态的奖励而放弃探索未知的状态而陷入局部最优，每架无人机通过不断试错地与环境进行交互，使长期累计奖励最大化。在时隙 n 中无人机的奖励包括无人机和用户成功通信的正奖励以及无人机违反碰撞约束和服务区域约束的负奖励，表示为

$$r_n=R_k-(\zeta_1 r_d+\zeta_2 r_D) \quad (14)$$

其中：r_d 和 r_D 分别为无人机违反碰撞约束和服务位置约束的奖励，ζ_1 和 ζ_2 为奖励系数。

4）状态转移概率。无人机下一状态的改变是由当前的状态空间和智能体的动作决定的，所以状态转移概率可表示为

$$p(s_{n+1}|s_n,a_n)=\begin{cases}1, & s_{n+1}\rightarrow s_n a_n,\ s_n\in S,\ a_n\in A\\ 0, & \text{其他}\end{cases} \quad (15)$$

2.2　DDPG 算法

不同于传统的 DRL 算法，DDPG 算法[9]将深度神经网络和 actor-critic 网络结合起来，并通过对智能体添加行为噪声和经验回放机制以增强训练过程的稳定性，共涉及 4 个神经网络：critic 目标网络 Q' 和 critic 当前网络 Q，actor 目标网络 μ' 和 actor 当前网络 μ，4 个神经网络的参数分别表示为 $\theta_{Q'}$，θ_Q，$\theta_{\mu'}$，θ_μ。critic 在 actor 的策略下计算动作值函数，critic 目标网络 Q' 和 actor 目标网络 μ' 用于计算更新目标。

critic 当前网络 Q 可由损失函数以反向传播的方式更新，损失函数为

$$L=\frac{1}{\mathcal{N}}\sum_{i=1}^{\mathcal{N}}\left[Y_i-Q(s_i,a_i|\theta_Q)\right]^2 \tag{16}$$

其中：$\mathcal{N}$为批处理样本大小，$Y_i=r_i+YQ'(s_{i+1},\mu'(s_{i+1}|\theta_{\mu'})|\theta_{Q'})$。通过损失函数 L 并基于后向传播方法求针对 Q 网络的梯度 $\nabla_{\theta_Q}L$，对其优化更新得到其参数 θ_Q。

actor 当前网络 μ 的输入为当前时隙 n 中的无人机状态 s_n，输出为当前状态下无人机的动作 a_n，其网络参数 θ_μ 更新遵循确定策略梯度定理，即

$$\nabla_{\theta_\mu\mu}|s_i=\frac{1}{\mathcal{N}}\sum_{i=1}^{\mathcal{N}}\nabla_a Q(s,a|\theta_Q)|_{s=s_i,a=\mu(s_i)}\nabla_{\theta_\mu\mu}(s|\theta_\mu)|_{s=s_i} \tag{17}$$

critic 目标网络 Q'和 actor 目标网络μ'采用软更新的方式计算更新目标，即

$$\begin{aligned}\theta_{Q'}&\leftarrow\tau\theta_Q+(1-\tau)\theta_{Q'}\\ \theta_{\mu'}&\leftarrow\tau\theta_\mu+(1-\tau)\theta_{\mu'}\end{aligned} \tag{18}$$

其中 τ 为软更新系数。

2.3 算法步骤

算法的训练过程由 E 个片段组成，actor 网络通过深度神经网络的参数 $\theta_{\mu'}$生成动作；然后从环境中观察当前状态 s_n，得到奖励值 r_n，并更新环境状态为 s_{n+1}。基于 DDPG 的无人机轨迹规划及功率控制算法如下。

算法 1 基于 DDPG 的无人机轨迹规划及功率控制算法

1 随机初始化 actor 网络和 critic 网络的权重
2 将 critic 和 actor 的参数拷贝给对应的目标网络 Q'和μ'的参数：$\theta_{Q'}\leftarrow\theta_Q$，$\theta_{\mu'}\leftarrow\theta_\mu$
3 清空经验缓冲池 $\mathcal{B}$
4 for each episode $e=1,2,\cdots,E$ do
5 初始化用户和无人机的位置信息，得到初始状态 s_1
6 for $n=1,2,\cdots,N$ do
7 根据噪声和当前策略得到动作 $a_n=\mu(s_n|\theta_\mu)+\xi$，$\xi$ 为随机噪声
8 无人机执行动作 a_n，得到奖励反馈和下一状态
9 if 无人机违反了位置约束和碰撞约束
10 重新校准位置信息
11 end if
12 if 缓冲池未满
13 则得到转换序列(s_n,a_n,r_n,s_{n+1})存储在$\mathcal{B}$中
14 else
15 将得到的转换序列随机替代缓冲池内的一组序列
16 从缓冲池中随机抽取一批序列作为 critic 和 actor 网络的训练数据
17 end if
18 使损失函数 L 最小化，更新当前 critic 的网络参数：
19 通过计算样本策略梯度 $\nabla_{\theta_\mu\mu}|s_i$，更新当前 actor 网络参数 θ_μ
20 以软更新的方式更新目标网络的参数 $\theta_{Q'}$，$\theta_{\mu'}$
21 $\theta_{Q'}\leftarrow\tau\theta_Q+(1-\tau)\theta_{Q'}$
$\theta_{\mu'}\leftarrow\tau\theta_\mu+(1-\tau)\theta_{\mu'}$
22 end for
23 end for

3 仿真结果与分析

为了验证所提基于 DDPG 的无人机轨迹规划及功率控制算法，通过 Python 搭建环境并进行仿真。服务区域 D 设置为 1 000×1 000 m 的正方形，并以此构建坐标系，用户位置固定且已知，无人机的最大飞行速度为 $v_{\max}=20$ m/s，且安全距离为 $d_{\min}=100$ m，飞行高度固定为 $H=100$ m。高斯噪声 $\sigma^2=-110$ dBm，参数距离为 1 m 时的信道功率增益为 $\rho_0=-60$ dB，无人机的最大发射功率为 $P_{\max}=0.1$ W。为了验证轨迹规划和功率控制对系统性能的影响，在 2 种不同的场景下进行仿真。

3.1 单无人机场景

在单无人机场景下，假设地面用户的数量为 5，且系统中没有其他无人机的干扰，无人机始终为最大发射功率，即 $P_m[n]=P_{\max}$。优化问题可简化为用户调度和轨迹规划的问题。此场景主要验证所用 DDPG 算法的优越性以及轨迹规划对系统性能的影响。

图 2 所示为在不同服务时间下单无人机的轨迹，无人机的起始位置为坐标原点。可见，随着 T 的增加，无人机的轨迹都向用户靠近。当 $T=150$ s 时，无人机会依次遍历所有用户并提供通信服务，且此时遍历轨迹为所有用户间的最短路径；当时间不足以遍历所有用户时，无人机的轨迹为向用户靠近的闭合曲线，以便获得更高的信道增益。

图 3 所示为不同优化算法下用户可达到的平均

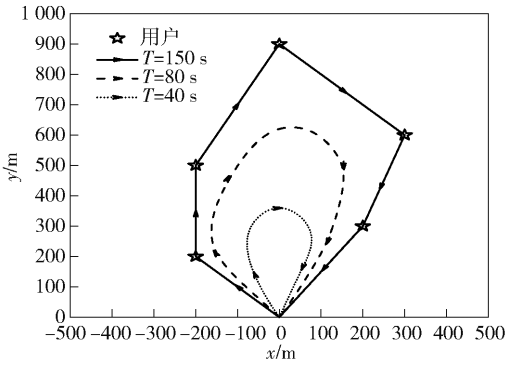

图 2　单无人机轨迹规划

速率。可见，当无人机位置固定时，速率是不变的，此时无人机和地面用户的位置固定，路径损耗不变，因此用户的传输速率不随时间的变化而改变。当无人机进行轨迹规划时，随着无人机服务时间的增加，用户的传输速率也增加并逐渐稳定，因为轨迹优化情况下的无人机可以接近用户，此时路径损耗降低，传输速率也相应地增加。实验过程中还对比了几种不同的优化算法，结果表明算法对系统性能的影响较小，但 DDPG 算法的收敛性更好，当无人机的轨迹趋于最优路径时，不同算法所获得的用户速率基本相同。

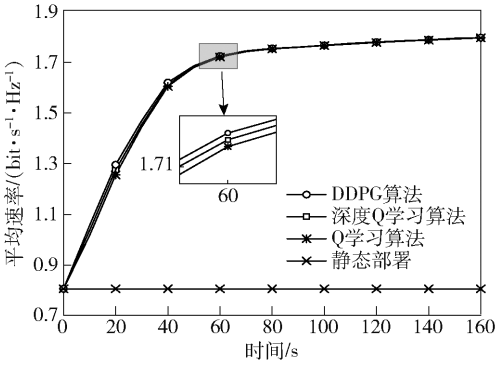

图 3　不同优化算法下的用户平均速率

3.2　双无人机场景

由图 1 可知，基站覆盖范围重叠部分的用户会受到其他无人机的干扰。因此在无人机数量为 2 和地面用户为 8 的场景下，通过 DDPG 算法对无人机的轨迹单独进行优化并对无人机轨迹和功率进行联合优化。在上述 2 种优化方案下进行仿真以验证轨迹规划和功率控制对系统性能的影响。

图 4 所示为对双无人机轨迹进行单独优化时的轨迹，无人机的起始位置坐标分别为（－200，0）和（200，0）。可见，当无人机的轨迹经过中心区域的 2 个用户时，通过轨迹规划可以减少对其他区域用户的干扰，如图中圆弧部分所示。此时无人机的轨迹会避开中间用户，避免造成干扰，而在遍历其他用户时始终保持最短距离。

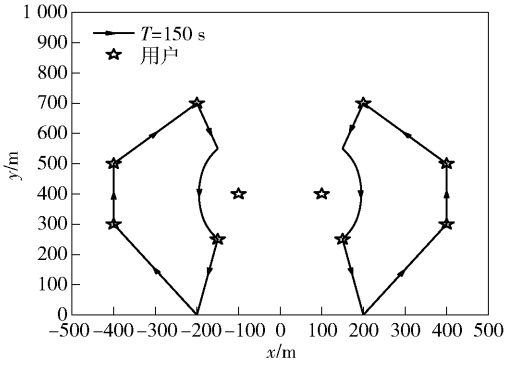

图 4　双无人机轨迹规划

图 5 所示为双无人机轨迹和功率联合优化时的轨迹，双无人机轨迹和单无人机类似，都是遍历所有用户的一个闭环。因为无人机可以对功率进行动态控制，在不需要刻意绕开中间用户的情况下降低对用户的干扰，拥有更好的信道增益。

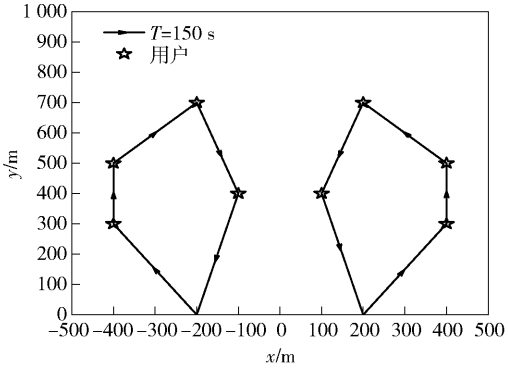

图 5　双无人机轨迹和功率联合优化的轨迹

图 6 所示为在双无人机场景下采用不同优化方案时的用户速率。可见，当基站固定时，用户速率不变且高于单无人机的场景。无人机轨迹和功率联合优化方案下用户的平均速率高于只对轨迹进行优化的方案，验证了所提算法的有效性。

图 7 所示为不同优化方案下用户可达到的平均传输速率。随着时间的增加，用户速率都增加且逐渐趋于稳定。双无人机轨迹和功率联合优化方案下用户可达到的平均速率最高，因为轨迹规划能够使无人机和用户之间拥有更好的信道增益。功率控制能够减少系统干扰，从而提高了用户的传输速率。

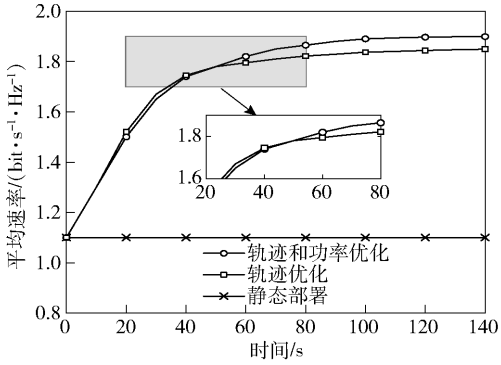

图 6 不同优化方案下的用户平均速率

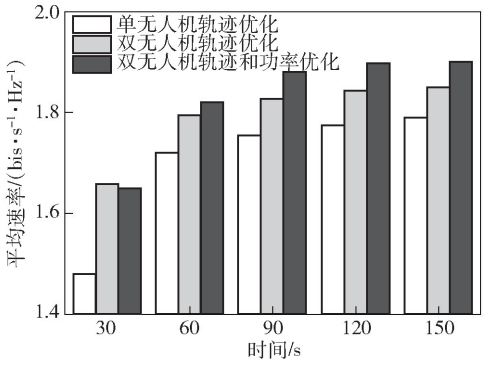

图 7 不同优化方案下的用户平均速率

4 结束语

提出了一种基于 DDPG 的无人机轨迹规划及功率控制算法。通过仿真实验对比了不同优化方案下用户可达到的传输速率,并对仿真结果进行分析。实验结果表明,与静态的无人机基站相比,所提算法能够有效地提升用户的传输速率。

参考文献:

[1] 陈新颖, 盛敏, 李博, 等. 面向6G的无人机通信综述[J]. 电子与信息学报, 2022, 44(3): 781-789.
CHEN X Y, SHENG M, LI B, et al. Survey on unmanned aerial vehicle communications for 6G[J]. Journal of Electronics & Information Technology, 2022, 44(3): 781-789.

[2] HOURANI A, KANDEEPAN S, LARDNER S. Optimal LAP altitude for maximum coverage[J]. IEEE Wireless Communication Letters, 2014, 3(6): 569-572.

[3] 张治, 熊天波, 陈建侨, 等. 无人机三维空地信道模型的空间特性研究[J]. 通信学报, 2020, 41(2): 123-130.
ZHANG Z, XIONG T B, CHEN J Q, et al. Research on the spatial characterization of a 3D UAV air-to-ground channel model[J]. Journal on Communications, 2020, 41(2): 123-130.

[4] LYU J B, ZENG Y, ZHANG R, et al. Placement optimization of UAV-mounted mobile base stations[J]. IEEE Communications Letters, 2017, 21(3): 604-607.

[5] ZENG Y, ZHANG R. Energy-efficient UAV communication with trajectory optimization[J]. IEEE Transactions on Wireless Communications, 2017, 16(6): 3747-3760.

[6] LIU M, GUI G, ZHAO N, et al. UAV-aided air-to-ground cooperative non-orthogonal multiple access[J]. IEEE Internet of Things Journal, 2019, 7(4): 2704-2715.

[7] TANG R, CHENG J, CAO Z. Joint placement design, admission control, and power allocation for NOMA-based UAV systems[J]. IEEE Wireless Communication Letters, 2020, 9(3): 385-388.

[8] ZHAO N, CHEN Y, PEI Y, et al. Deep reinforcement learning for trajectory design and power allocation in UAV networks[C]// ICC 2020. Piscataway, NJ: IEEE Press, 2020: 1-6.

[9] 邹伟, 鬲玲, 刘昱杓. 强化学习[M]. 北京: 清华大学出版社, 2019: 244-266.
ZOU W, GE L, LIU Y B. Reinforcement learning[M]. Beijing: Tsinghua University Press, 2019: 244-266.